

DDPM 核心原理与数学推演

去噪扩散概率模型备忘录

AIGC 底层算法逻辑留档

2026 年 5 月 5 日

Executive Summary | 核心摘要

去噪扩散概率模型 (DDPM, Denoising Diffusion Probabilistic Models) 的本质是一个基于马尔可夫链的参数化生成模型。其核心思想分为两步：首先通过**前向过程**向图像中逐步注入高斯噪声，直至其变为纯噪声；随后训练一个搭载了时间编码的神经网络（通常为 U-Net）来学习**逆向过程**，通过逐步预测并剔除噪声，实现从纯粹的随机分布中“雕刻”出高清图像。

1 前向过程 (Forward Process): 制造“训练数据”

前向过程是一个没有可学习参数的纯数学马尔可夫链。我们在 T 个时间步内，逐步向真实图像 x_0 中添加方差调度的标准高斯噪声。

1.1 1. 单步递推公式

在任意时间步 t ，图像 x_t 由上一步 x_{t-1} 添加微小噪声得到：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I})$$

其中， β_t 是预设的噪声方差（通常随 t 逐渐增大，范围在 $0.0001 \sim 0.02$ 之间）。

1.2 2. 一步到位公式 (Reparameterization Trick)

由于高斯分布具有极其优美的**线性可加性**，我们可以直接跳过繁琐的 t 次循环，利用代数推导得出从原图 x_0 直接生成任意 t 时刻脏图 x_t 的闭式解：

定义 $\alpha_t = 1 - \beta_t$ ，并令 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，则有：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

写成最直观的张量加法形式即为：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$$

(其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 为计算机掷骰子产生的标准高斯噪声。此公式彻底打通了工程训练的算力瓶颈。)

2 模型训练 (Training): 闭卷考试与误差反向传播

训练的目标不是让神经网络预测原图 x_0 , 而是让神经网络 ϵ_θ 预测出 “在第 t 步时, 到底往里加了什么噪声”。

2.1 1. 损失函数 (Loss Function)

得益于 DDPM 作者推导出的极简损失函数 (Simplified Loss), 模型只需要计算 “真实加入的噪声 ϵ ” 与 “AI 预测的噪声 ϵ_θ ” 之间的均方误差 (MSE):

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\underbrace{\sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon}_{x_t}, t \right) \right\|^2 \right]$$

2.2 2. 核心机制: 时间编码 (Time Embedding) 与权重共享

整个 1000 步的去噪过程共用同一个 U-Net 黑盒 (权重共享)。为区分不同的破坏程度, 时间步 t 会被转化为正弦位置编码 (类似 Transformer), 作为条件注入到神经网络的每一层中, 引导模型调整当下的 “嗅探灵敏度”。

3 逆向过程 (Reverse Process): 从虚无中雕刻

当模型训练收敛且参数冻结 (Frozen) 后, 进入纯推理阶段。我们从纯高斯噪声 $x_T \sim \mathcal{N}(0, \mathbf{I})$ 开始, 执行 T 次循环逆推。

基于贝叶斯定理与网络预测的噪声 $\epsilon_\theta(x_t, t)$, 单步去噪的数学期望推导如下:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t \mathbf{z}$$

- **代数剔除:** 等式前半部分利用 AI 预测的噪声 ϵ_θ 将画面还原。
- **朗之万动力学注入 ($+\sigma_t \mathbf{z}$):** 其中 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ 。在 $t > 1$ 时, 故意向画面中重新注入微小的新噪声。这是防止生成图像过度平滑 (磨皮感)、逼迫网络在下一步继续生成丰富高频纹理细节的核心魔法。

工业级演进备注: 上述计算在像素级矩阵 (如 1024×1024) 上极其缓慢。Stable Diffusion 等架构引入了 VAE 变分自编码器, 将整个加噪/去噪过程降维压缩至潜空间 (Latent Space) (如 64×64) 中进行, 实现了算力与速度的断崖式飞跃。